Przemek Wołczacki, czerwiec 2021
Projekt ze Sztucznej inteligencji: Grupowanie i klasyfikacja danych

Podstawowe dane dotyczące komputera, na którym wykonano zadania:

Laptop ASUS TUF GAMING A15,

GPU: NVIDIA GeForce RTX 2060,
CPU: AMD Ryzen z serii 4000,
RAM: 16 GB DDR4,
DYSK: SSD 512 GB,
System: Windows 10, 64-bit.

Projekt wykonany w *Python Notebook Jupyter*.

In [1]:
```
import numpy as np
import pandas as pd
import xgboost as xgb
import seaborn as sns
import sys
import warnings
warnings.filterwarnings("ignore")

import matplotlib.pyplot as plt
%matplotlib inline

from IPython.display import Markdown, display

import sklearn
from sklearn import preprocessing
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error as MSE
from sklearn.metrics import accuracy_score
from sklearn.inspection import permutation_importance
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans
from sklearn.cluster import DBSCAN
```

Klasyfikacja

Zbiór danych użyty do klasyfikacji: *titanic.csv*

https://www.kaggle.com/c/titanic/data?select=test.csv (1309 osób i 14-ście informacji o każdej z nich)

Krótki opis zbioru:
Zbiór zawiera informacje na temat pasażerów legendarnego Titanica.

Opis najważniejszych zmiennych:
pclass - typ klasy pasażerskiej (1-najlepsza),
survived - czy przeżył (1-tak, 0-nie),
sex - płeć,
age - wiek,
sbibsp - rodzeństwo/małżonkowie na pokładzie (tak/nie),
parch - liczba rodziców/dzieci na pokładzie,

Klasyfikacja będzie dotyczyła tego czy osoba płynąca Titanic'iem przeżyła katastrofe.
Atrybut decyzyjny - kolumna ***'survived'***.
Mamy dwie możliwości: **0** - osoba nie przeżyła, **1** - osoba przeżyła
Algorytmy klasyfikacji wybrane przeze mnie. ***XGBoost*** i ***RandomForest***

Pierwszo ze zbioru usunąłem wiersze z kolumny *Age*, w których brakowało wartości. Następnie, pozostałe informacje o wieku pasażera zamieniłem na zera bądź jedynki (w zależności od tego czy osoba miała poniżej, czy powyżej 18 lat). Typom *male* i *female* z kolumny mówiącej o płci - również przypisałem 0 lub 1, żeby operować na samych zmiennych numerycznych. Natomiast reszte kolumn mających braki w danych i kolumn według mnie mało istotnych, takich jak np. cel podróży (*ang.* home_dest) - wyrzuciłem.

In [2]:
```
df = pd.read_csv('titanic2.csv')
display(df)

df = df.dropna(subset=['age'])
df['age'] = df['age'].apply(lambda x: int(x >= 18))
df['sex'] = df['sex'].apply(lambda x: int(x == 'male'))
print(df.isnull().any())
df = df.dropna(axis=1)
df.drop(['name', 'ticket'], axis=1, inplace=True)

Y = df['survived']
X = df.drop(['survived'], axis=1)

display(df)
```

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home_dest
0	1	1	Allen, Miss. Elisabeth Walton	female	29.0000	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	Allison, Master. Hudson Trevor	male	0.9167	1	2	113781	151.5500	C22 C26	S	11	NaN	Montreal, PQ / Chesterville, ON
2	1	0	Allison, Miss. Helen Loraine	female	2.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1	2	113781	151.5500	C22 C26	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.0000	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1304	3	0	Zabour, Miss. Hileni	female	14.5000	1	0	2665	14.4542	NaN	C	NaN	328.0	NaN
1305	3	0	Zabour, Miss. Thamine	female	NaN	1	0	2665	14.4542	NaN	C	NaN	NaN	NaN
1306	3	0	Zakarian, Mr. Mapriededer	male	26.5000	0	0	2656	7.2250	NaN	C	NaN	304.0	NaN
1307	3	0	Zakarian, Mr. Ortin	male	27.0000	0	0	2670	7.2250	NaN	C	NaN	NaN	NaN
1308	3	0	Zimmerman, Mr. Leo	male	29.0000	0	0	315082	7.8750	NaN	S	NaN	NaN	NaN

1309 rows × 14 columns

```
pclass       False
survived     False
name         False
sex          False
age          False
sibsp        False
parch        False
ticket       False
fare          True
cabin         True
embarked      True
boat          True
body          True
home_dest     True
dtype: bool
```

	pclass	survived	sex	age	sibsp	parch
0	1	1	0	1	0	0
1	1	1	1	0	1	2
2	1	0	0	0	1	2
3	1	0	1	1	1	2
4	1	0	0	1	1	2
...	...	...	...	...	...	...
1301	3	0	1	1	0	0
1304	3	0	0	0	1	0
1306	3	0	1	1	0	0
1307	3	0	1	1	0	0
1308	3	0	1	1	0	0

1046 rows × 6 columns

Stosunek zbioru treningowego do testowego ustawiony na *8:2*

In [3]:
```
seed=27

train_X, test_X, train_Y, test_Y = train_test_split(X, Y,
                      test_size = 0.2, random_state = seed)

def model_train(model, train_X, test_X, train_Y, test_Y):
    model.fit(train_X, train_Y)
    pred = model.predict(test_X)
    print ('Accuracy: ', accuracy_score(test_Y, pred))

print("XGBoost:")
model_train(xgb.XGBClassifier(use_label_encoder =False, eval_metric='mlogloss'), train_X, test_X, train_Y, test_Y)
print("\nRandomForest:")
model_train(RandomForestClassifier(), train_X, test_X, train_Y, test_Y)
```

```
XGBoost:
Accuracy:  0.8285714285714286

RandomForest:
Accuracy:  0.819047619047619
```

Przetestowałem również działanie klasyfikatorów na zbiorze bez zmiany wieku na *0/1*

In [4]:
```
df = pd.read_csv('titanic2.csv')
df = df.dropna(subset=['age'])
df['sex'] = df['sex'].apply(lambda x: int(x == 'male'))

df = df.dropna(axis=1)
df.drop(['name', 'ticket'], axis=1, inplace=True)
Y = df['survived']
X = df.drop(['survived'], axis=1)

train_X, test_X, train_Y, test_Y = train_test_split(X, Y,
                      test_size = 0.2)

print("XGBoost:")
model_train(xgb.XGBClassifier(use_label_encoder =False, eval_metric='mlogloss'), train_X, test_X, train_Y, test_Y)
print("\nRandomForest:")
model_train(RandomForestClassifier(), train_X, test_X, train_Y, test_Y)
```

```
XGBoost:
Accuracy:  0.8095238095238095

RandomForest:
Accuracy:  0.7761904761904762
```

Generalnie z wiekiem zero-jedynkowym wyniki algorytmów są lepsze. Poza tym oba algorytmy mają przybliżoną dokładność.

Stosunek zbioru treningowego do testowego ustawiony na *7:3*

In [5]:
```
train_X, test_X, train_Y, test_Y = train_test_split(X, Y,
                      test_size = 0.3, random_state = seed)

def model_train(model, train_X, test_X, train_Y, test_Y):
    model.fit(train_X, train_Y)
    pred = model.predict(test_X)
    print ('Accuracy: ', accuracy_score(test_Y, pred))

print("XGBoost:")
model_train(xgb.XGBClassifier(use_label_encoder =False, eval_metric='mlogloss'), train_X, test_X, train_Y, test_Y)
print("\nRandomForest:")
model_train(RandomForestClassifier(), train_X, test_X, train_Y, test_Y)
```

```
XGBoost:
Accuracy:  0.7929936305732485

RandomForest:
Accuracy:  0.7898089171974523
```

Stosunek zbioru treningowego do testowego ustawiony na *6:4*

In [6]:
```
train_X, test_X, train_Y, test_Y = train_test_split(X, Y,
                      test_size = 0.4, random_state = seed)

def model_train(model, train_X, test_X, train_Y, test_Y):
    model.fit(train_X, train_Y)
    pred = model.predict(test_X)
    print ('Accuracy: ', accuracy_score(test_Y, pred))

print("XGBoost:")
model_train(xgb.XGBClassifier(use_label_encoder =False, eval_metric='mlogloss'), train_X, test_X, train_Y, test_Y)
print("\nRandomForest:")
model_train(RandomForestClassifier(), train_X, test_X, train_Y, test_Y)
```

```
XGBoost:
Accuracy:  0.7875894988066826

RandomForest:
Accuracy:  0.7947494033412887
```

W zależności od stosunku zbioru treningowego do testowego, ale też i od obserwacji wylosowanych do poszczególnych grup - wyniki klasyfikacji oscylują w okolicy 80% dokładności (_ang._ accuracy).

Poza klasyfikacją przeanalizowałem cały zbiór za pomocą wykresów.

Ile osób przeżyło, a ile zginęło:

In [7]:
```
sns.set_palette("Set1")
sns.catplot(data=df,
          x='survived',
          kind='count')
plt.show()
```

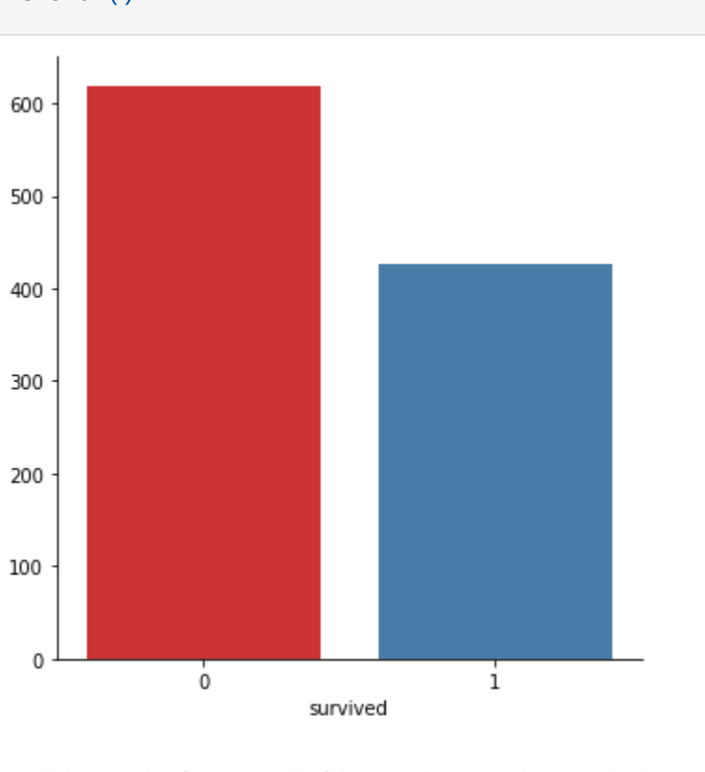

Czy klasa którą podróżowały osoby, miała wpływ na przeżycie?

1 – to klasa najwyższa (premium). Być może, osoby podróżujące tą klasą, miały priorytet przy ewakuacji, analogicznie do osób wsiadających do samolotu na lotnisku, a być może ich kajuty, były zlokalizowane w specyficznej części statku. Ułatwiającej lub utrudniającej ewakuację.

In [8]:
```
sns.catplot(data=df,
          x='pclass',
          kind = 'count',
          hue= 'survived')
plt.show()
```

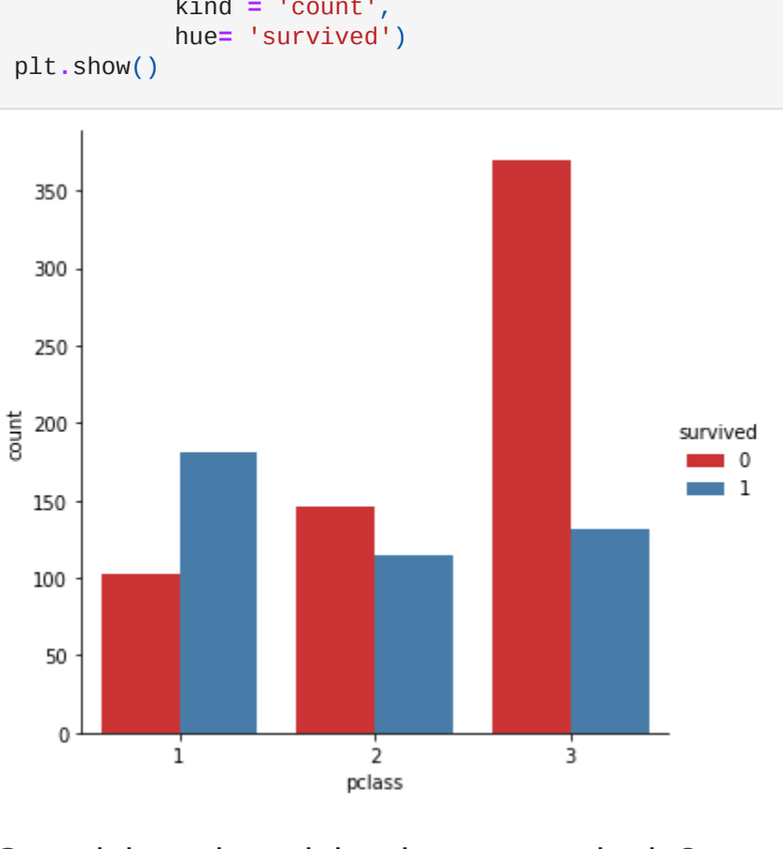

Czy wiek osoby, miał wpływ na przeżycie?

Widzimy, że większość dzieci przeżyła. Nie ma widocznej różnicy, dla osób po 20 roku życia.
Zapewne dzieci były traktowane priorytetowo.

In [9]:
```
sns.distplot(df[df['age'].notnull() & (df['survived']==1)]['age'],
           kde_kws={"label": "Survived"},
           bins=10)
sns.distplot(df[df['age'].notnull() & (df['survived']==0)]['age'],
           kde_kws={"label": "Not Survived"},
           bins=10)
plt.show()
```

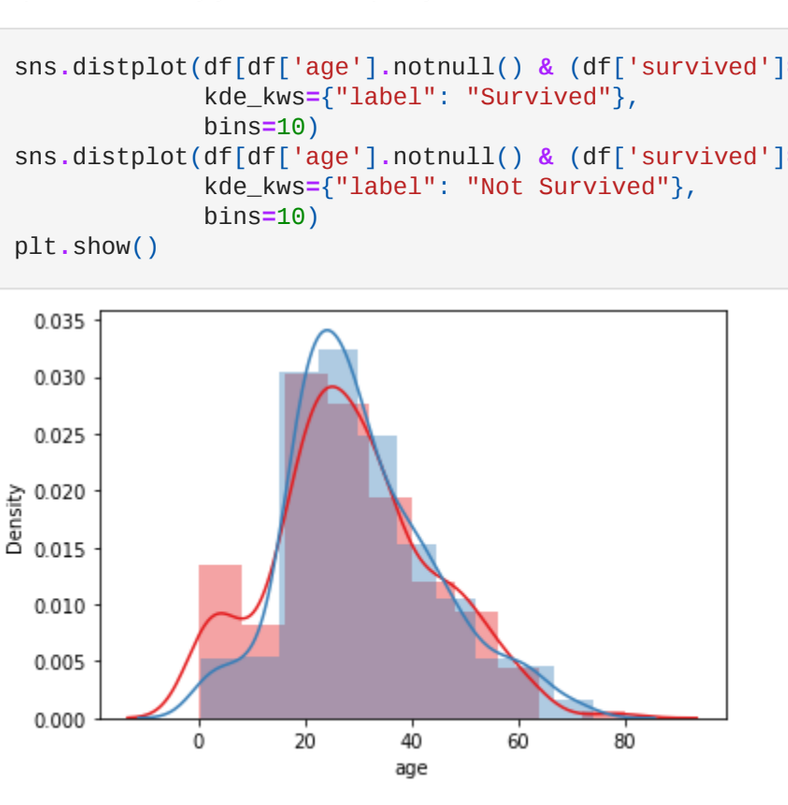

Czy płeć osoby, miała wpływ na przeżycie?

Kobiety miały większe szanse na przeżycie. Prawdopodobnie miały pierwszeństwo

In [10]:
```
sns.catplot(data=df,
          x = 'sex',
          hue = 'survived',
          kind='count')
plt.show()
```

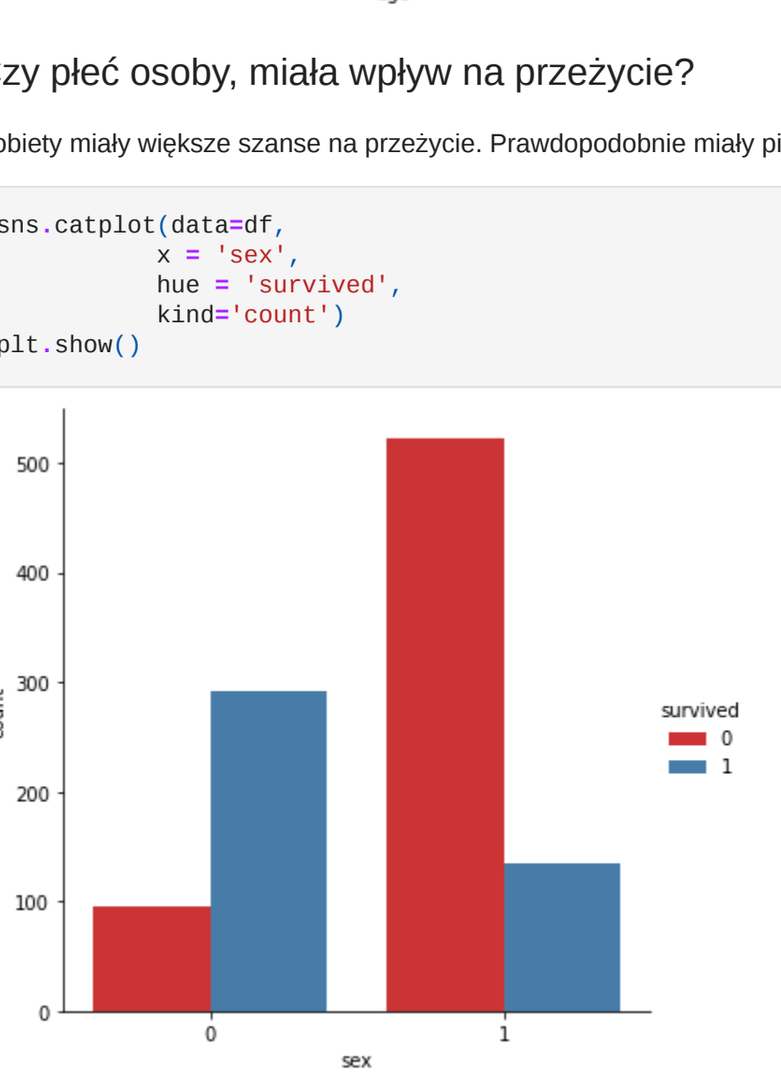

Klasteryzacja

Zbiór danych użyty do klasteryzacji: *multishapes.csv*

https://www.rdocumentation.org/packages/factoextra/versions/1.0.7/topics/multishapes (1100 obserwacji i 3 zmienne)

Krótki opis zbioru:
Dane zawierające klastry dowolnych kształtów.

Opis zmiennych:
x - wektor numeryczny zawierający współrzędne obserwacji x,
y - wektor numeryczny zawierający współrzędne obserwacji y,
shapes - wektor numeryczny odpowiadający numerowi klastra każdej obserwacji.

Algorytmy klasteryzacji wybrane przeze mnie. ***KMeans*** i ***DBScan***

Jeśli chodzi o obróbke danych to trzeba było je przeskalować, aby poszczególne pomiary nie dominowały w późniejszych obliczeniach.

In [11]:
```
multishapes = pd.read_csv("multishapes.csv")
ms_df = multishapes[['x','y']]
ms_df.describe()

scaled_df = pd.DataFrame(preprocessing.scale(ms_df), index=multishapes['shape'], columns = ms_df.columns)
scaled_df.describe()

scaled_df
```

Out[11]:

	x	y
shape		
1	-1.120749	-0.193616
1	1.448907	0.844692
1	1.564203	0.298161
1	-1.041463	0.096855
1	1.222429	1.221561
...	...	...
6	1.609007	-1.572253
6	1.569755	-1.480985
6	1.660958	-1.573442
6	1.644896	-1.711540
6	1.866296	-1.695783

1100 rows × 2 columns

Przedstawienie zbioru w formie graficznej

In [12]:
```
msplot = scaled_df.plot.scatter(x='x',y='y',c='Black',title="Multishapes data",figsize=(11,8.5))
msplot.set_xlabel("X")
msplot.set_ylabel("Y")
plt.show()
```

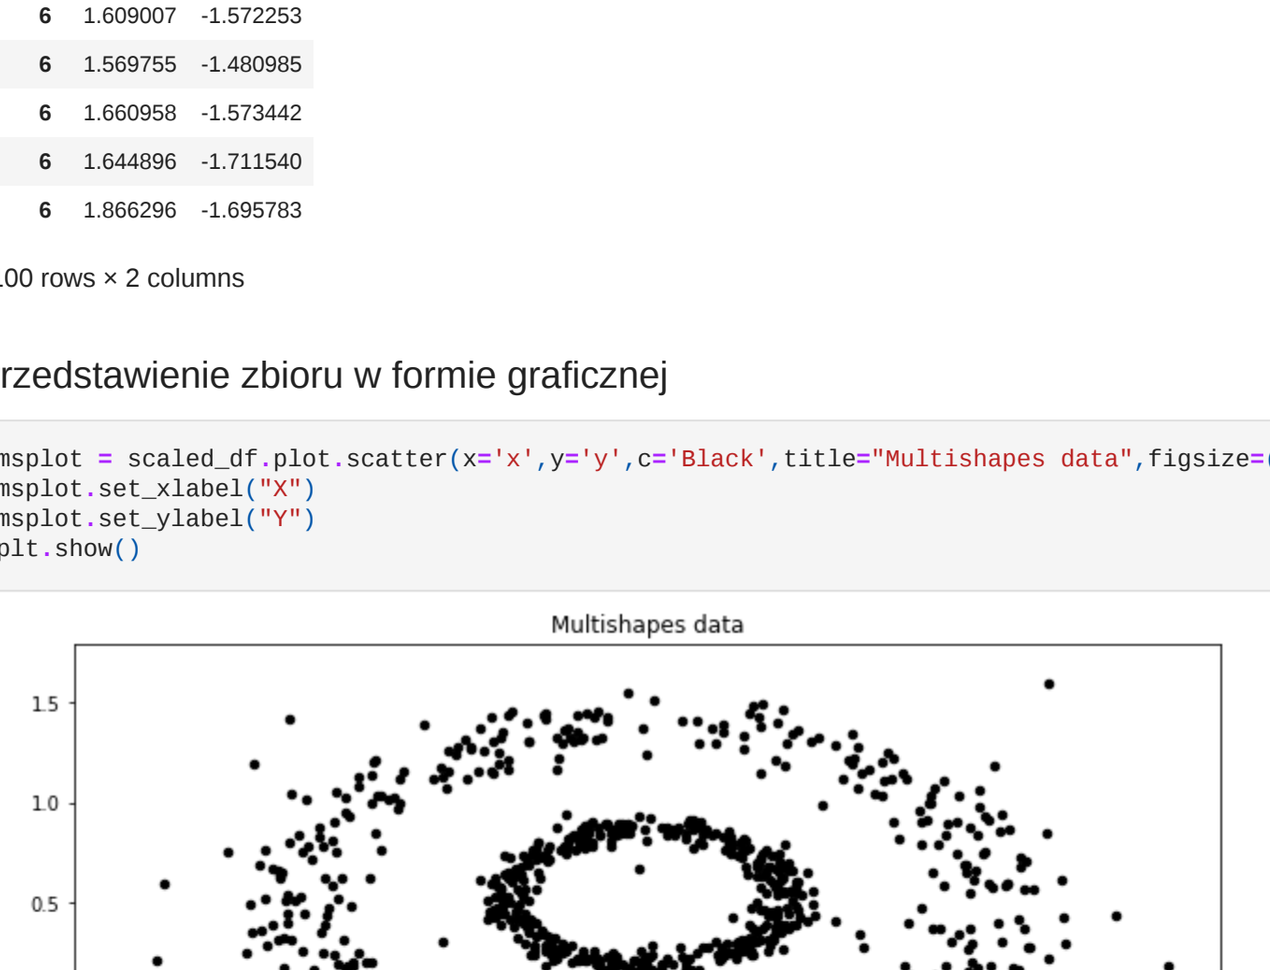

KMeans

Do znalezienia 'optymalnej' liczby klastrów - ręcznie zapętliłem algorytm *KMeans* , aby później przedstawić jego wyniki na wykresie i wybrać najlepsze *n*.

In [13]:
```
from sklearn.metrics import silhouette_score

scores = [0]
for i in range(2,11):
    fitx = KMeans(n_clusters=i, init='random', n_init=5, random_state=109).fit(scaled_df)
    score = silhouette_score(scaled_df, fitx.labels_)
    scores.append(score)

plt.figure(figsize=(11,8.5))
plt.plot(range(1,11), np.array(scores), 'bx-')
plt.xlabel('Number of clusters $k$')
plt.ylabel('Average Score')
plt.show()
```

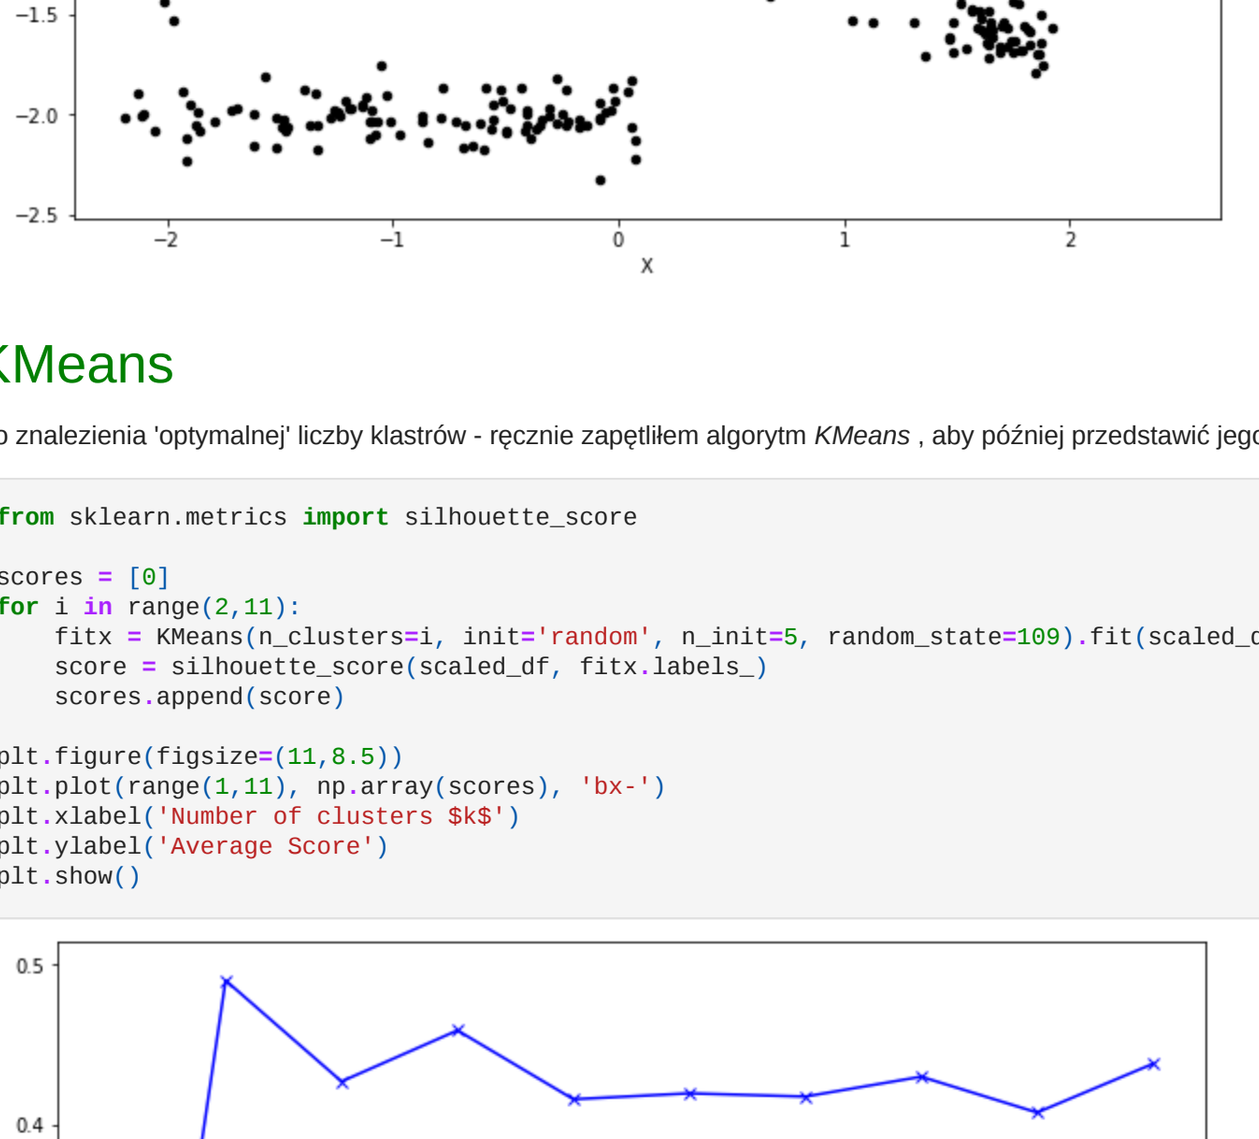

Wykres sugeruje za *n* przyjąć 2.

n_clusters = 2

In [14]:
```
ms_kmeans = KMeans(n_clusters=2, init='random', n_init=2, random_state=109).fit(scaled_df)

plt.figure(figsize=(10,10))
plt.scatter(scaled_df['x'],scaled_df['y'], c=ms_kmeans.labels_);
plt.scatter(ms_kmeans.cluster_centers_[:,0],ms_kmeans.cluster_centers_[:,1], c='r', marker='h', s=100);
```

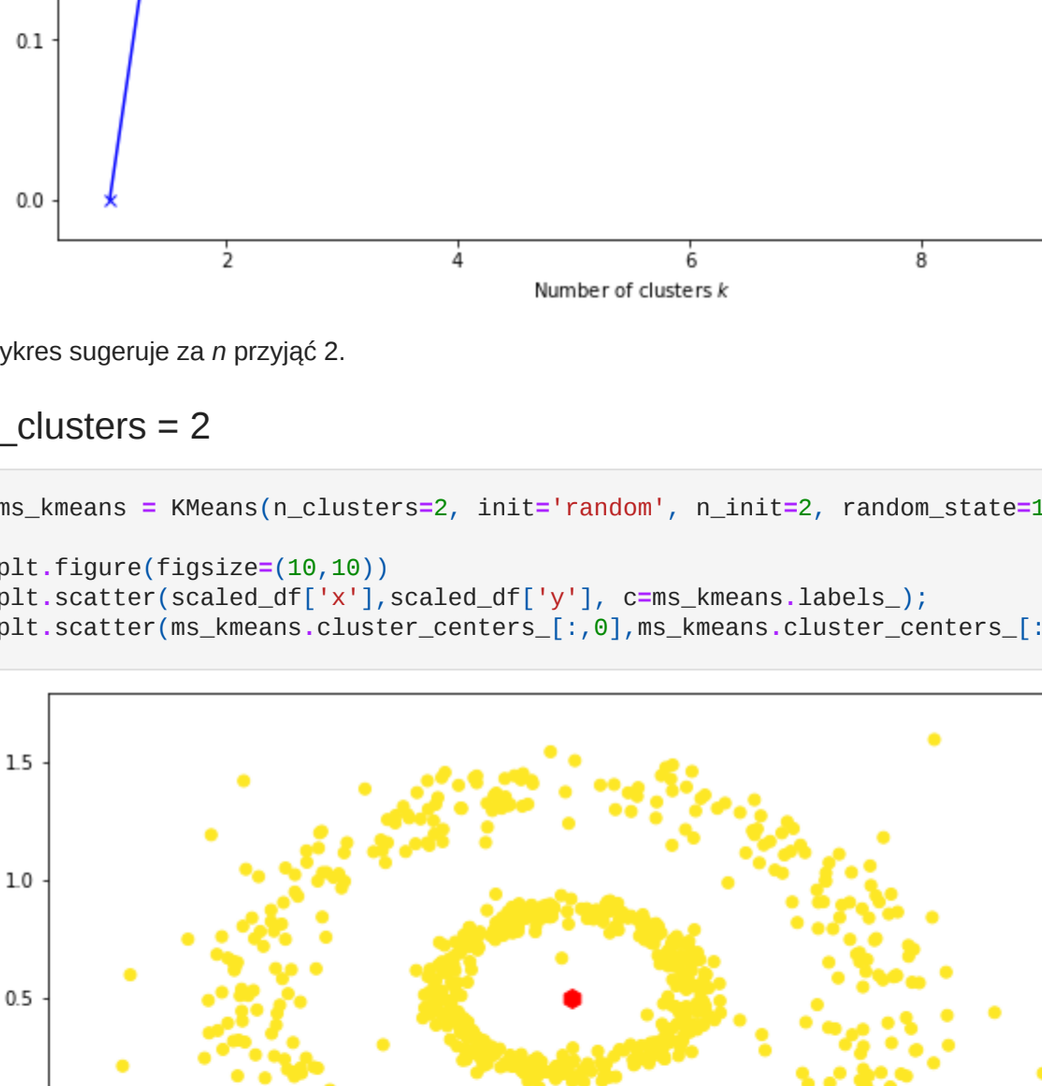

n_clusters = 3

In [15]:
```
ms_kmeans = KMeans(n_clusters=3, init='random', n_init=3, random_state=109).fit(scaled_df)

plt.figure(figsize=(10,10))
plt.scatter(scaled_df['x'],scaled_df['y'], c=ms_kmeans.labels_);
plt.scatter(ms_kmeans.cluster_centers_[:,0],ms_kmeans.cluster_centers_[:,1], c='r', marker='h', s=100);
```

n_clusters = 5

In [16]:
```
ms_kmeans = KMeans(n_clusters=5, init='random', n_init=5, random_state=109).fit(scaled_df)

plt.figure(figsize=(10,10))
plt.scatter(scaled_df['x'],scaled_df['y'], c=ms_kmeans.labels_);
plt.scatter(ms_kmeans.cluster_centers_[:,0],ms_kmeans.cluster_centers_[:,1], c='r', marker='h', s=100);
```

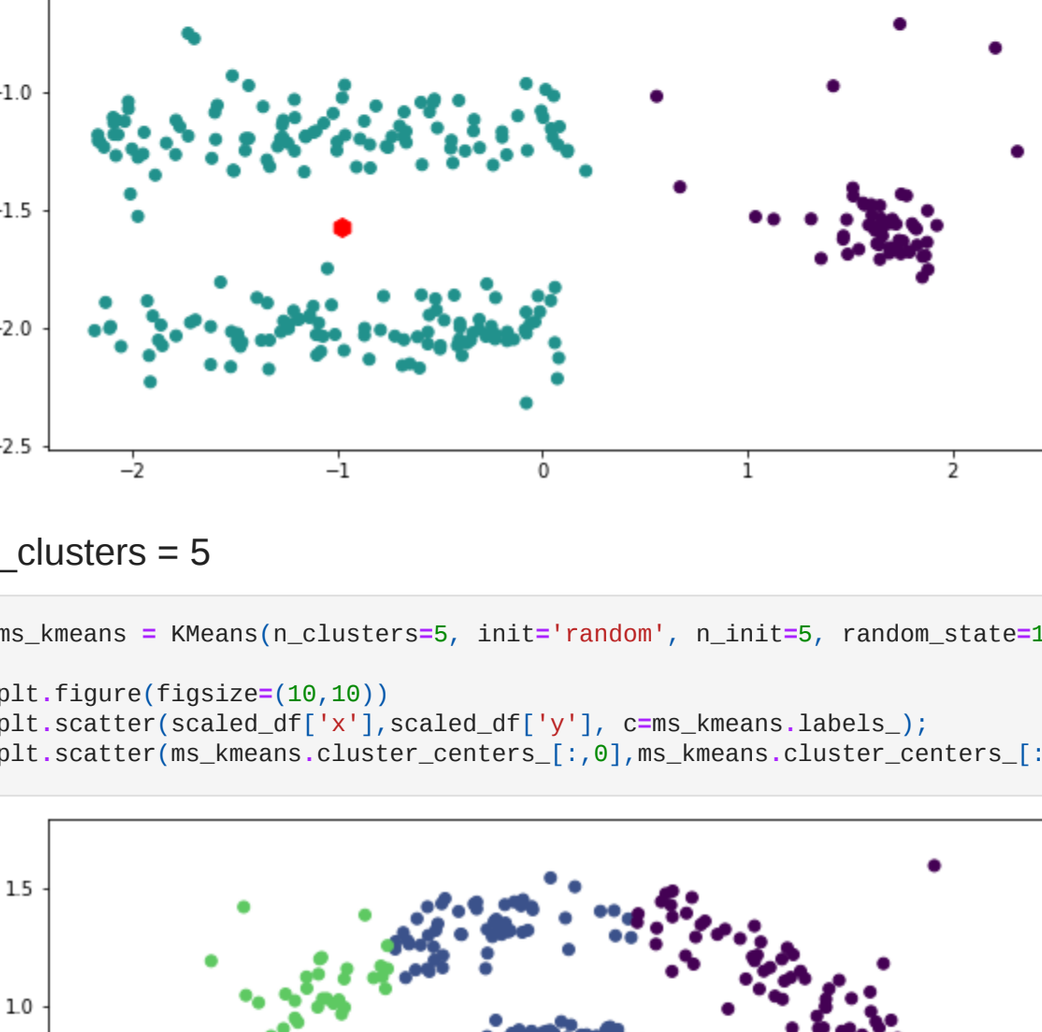

Jak widać na wykresach wybór odpowiedniej liczby klastrów jest bardzo ważny do prawidłowej klasteryzacji.

VS
DBScan

Zamiast obserwować jak wartość *epsilon* wpływa na klastrowanie *DBScan*'em w pętli (co byłoby czasochłonne i dla dużych, wysokowymiarowych danych złożone obliczeniowo), możemy sprawdzić, jak daleko każdy punkt ma do N-tego najbliższego sąsiada.

In [17]:
```
from sklearn.neighbors import NearestNeighbors

def plot_epsilon(df, min_samples):
    fitted_neigbors = NearestNeighbors(n_neighbors=min_samples).fit(df)
    distances, indices = fitted_neigbors.kneighbors(df)
    dist_to_nth_nearest_neighbor = distances[:,-1]
    plt.plot(np.sort(dist_to_nth_nearest_neighbor))
    plt.xlabel("Index\n(sorted by increasing distances)")
    plt.ylabel("Epsilon")
    plt.tick_params(right=True, labelright=True)
```

In [18]:
```
plot_epsilon(scaled_df, 3)
```

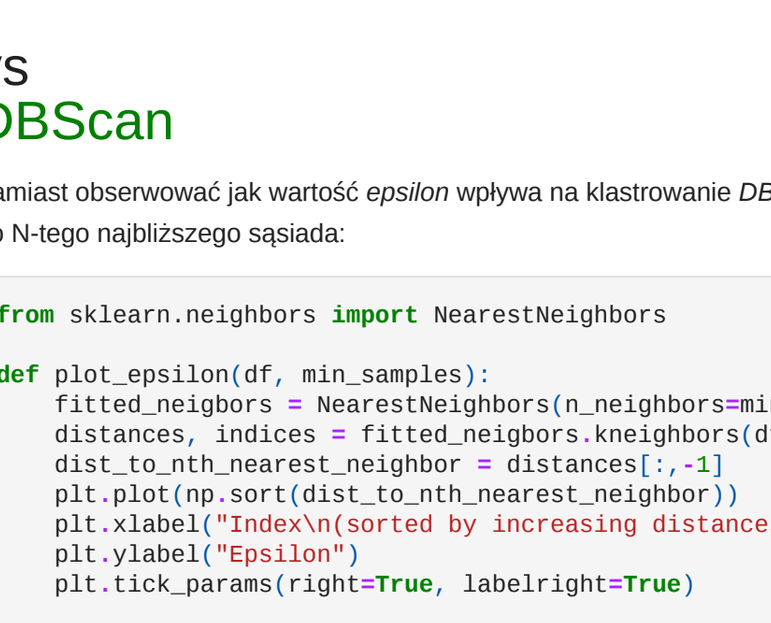

Na podstawie wykresu *eps = 0.2* będzie najefektywniejszy.

eps = 0.1

In [19]:
```
plt.figure(figsize=(11,8.5))
fitted_dbscan = DBSCAN(eps=0.1).fit(scaled_df)
plt.scatter(scaled_df['x'],scaled_df['y'], c=fitted_dbscan.labels_);
```

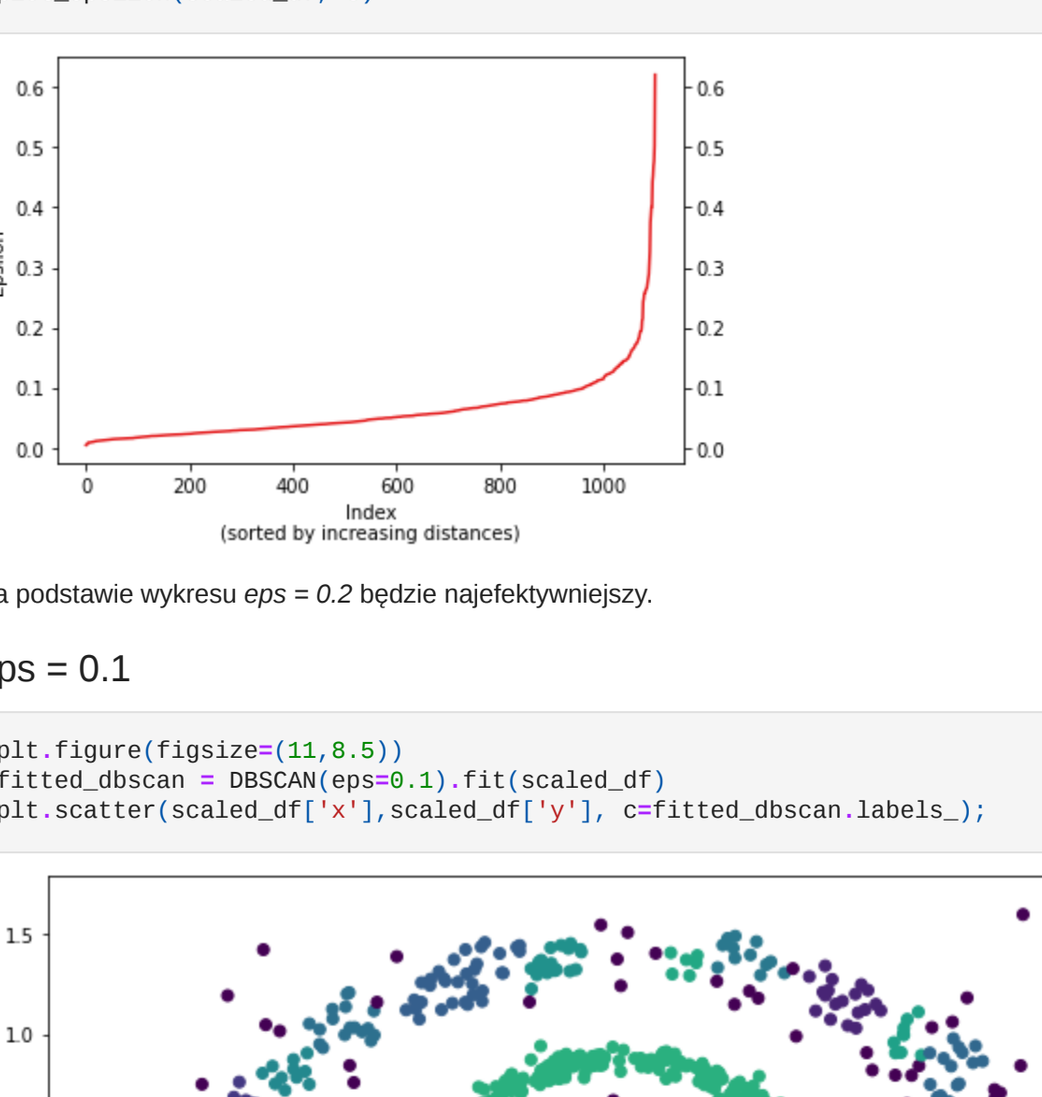

eps = 0.2

In [20]:
```
plt.figure(figsize=(11,8.5))
fitted_dbscan = DBSCAN(eps=0.2).fit(scaled_df)
plt.scatter(scaled_df['x'],scaled_df['y'], c=fitted_dbscan.labels_);
```

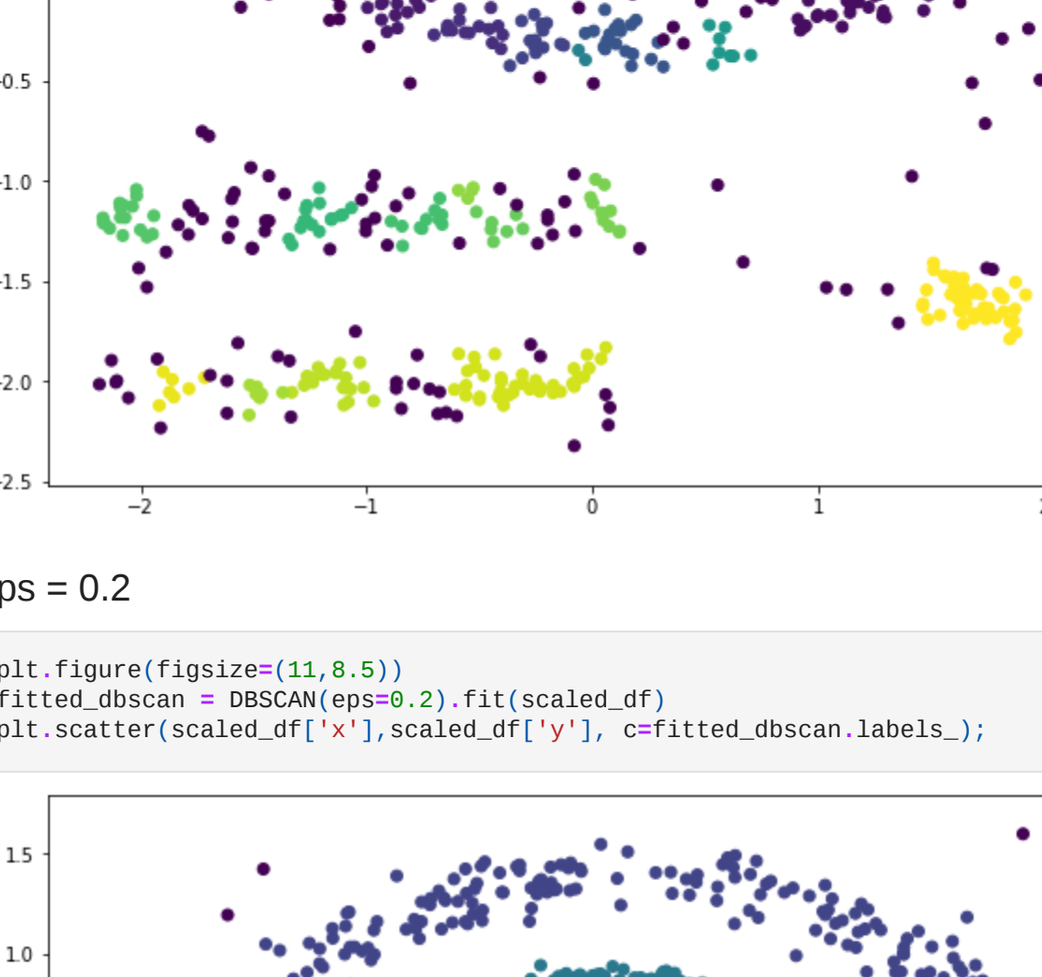

eps = 0.6

In [21]:
```
plt.figure(figsize=(11,8.5))
fitted_dbscan = DBSCAN(eps=0.6).fit(scaled_df)
plt.scatter(scaled_df['x'],scaled_df['y'], c=fitted_dbscan.labels_);
```

Tak samo tutaj słabo dobrany epsilon będzie dawał słabe wyniki, tak więc warto znać funkcje, dzięki którym z łatwością określimy najlepsze parametry.

In [ ]: